

T.C.
BANDIRMA ONYEDİ EYLÜL ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ



LİSANS BİTİRME PROJESİ

PROJE BAŞLIĞI

**MOBİL CİHAZLARDA GERÇEK ZAMANLI YAPRAK HASTALIĞI
SEGMENTASYONU VE PSEUDO-SPEKTRAL ANALİZ TABANLI KARAR
DESTEK SİSTEMİ**

Fatih Taşkın

2111504031

Hazan Ezgi Erçin

2311504299

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Dr. Öğr. Üyesi Alpay Doruk

HAZİRAN 2026

İÇİNDEKİLER

ÖZET	3
SİMGELER VE KISALTMALAR LİSTESİ.....	3
1. GİRİŞ	4
1.1. Problemin Tanımı ve Önemi.....	5
1.2. Projenin Kapsamı ve Hedefleri	5
1.3. Literatür Özeti	5
2. TEKNOLOJİK ALTYAPI VE ARAÇLAR.....	5
2.1. Programlama Dilleri ve Frameworkler	5
2.2. Görüntü İşleme ve Yapay Zeka Kütüphaneleri.....	6
3. KURAMSAL TEMELLER VE YÖNTEM.....	7
3.1. Veri Seti ve Etiketleme	7
3.2. Veri Ön İşleme ve Veri Artırma	8
3.3. Model Mimarisi.....	8
3.4. Pseudo-Spektral (NIR) Bant Tahmini	9
3.5. Mobil Optimizasyon	9
3.6. Deneysel Sonuçlar ve Performans Analizi.Hata! Yer işareti tanımlanmamış.	
3.6.1 Değerlendirme Metrikleri.....	Hata! Yer işareti tanımlanmamış.
3.6.2 Eğitim ve Test Sonuçları.....	10Hata! Yer işareti tanımlanmamış.
3.6.3 Pseudo-NIR Bant Katkısının Analizi.....	Hata! Yer işareti tanımlanmamış.
3.6.4 Mobil Performans Sonuçları.....	Hata! Yer işareti tanımlanmamış.
4. TASARIM VE UYGULAMA	11
4.1. Sistem Mimarisi ve Genel İş Akışı	11
4.2. Mobil Görüntü Edinimi ve Ön İşleme Süreci	11
4.3. TensorFlow Lite Model Entegrasyonu	12
4.4. Gerçek Zamanlı Segmentasyon ve Pseudo-Spektral Analiz	12

4.5. Kullanıcı Arayüzü Tasarımı	Hata! Yer işareti tanımlanmamış.
4.6. Mobil Performans ve Kaynak Kullanımı Değerlendirmesi	13
5. SONUÇ VE DEĞERLENDİRME.....	13
5.1. Mevcut Durum Analizi.....	14
5.2. Gelecek Çalışmalar ve Planlanan Geliştirmeler	Hata! Yer işareti tanımlanmamış.
KAYNAKLAR	15
ÖZGEÇMİŞ	19
16	

ÖZET

Tarımsal üretimde karşılaşılan bitki hastalıkları, yalnızca ürün miktarını değil aynı zamanda ürün kalitesini de olumsuz yönde etkilemektedir. Özellikle yaprak üzerinde oluşan fungal, bakteriyel ve viral kaynaklı hastalıklar, fotosentez mekanizmasını doğrudan etkileyerek bitkinin gelişim sürecini sekteye uğratmaktadır. Bu durum, hem küçük ölçekli üreticiler hem de endüstriyel tarım uygulamaları açısından ciddi ekonomik kayıplara neden olmaktadır.

Geleneksel hastalık tespit süreçleri, çoğunlukla saha gözlemi ve uzman değerlendirmesine dayalıdır. Bu yöntemler, yüksek doğruluk sağlayabilmesine rağmen zaman alıcı olmaları, insan hatasına açık olmaları ve her bölgede uzman erişiminin mümkün olmaması gibi dezavantajlara sahiptir. Bu bağlamda, otomatik ve taşınabilir karar destek sistemlerine olan ihtiyaç her geçen gün artmaktadır.

Bu tez çalışmasında, mobil cihazlar üzerinde gerçek zamanlı olarak çalışabilen, derin öğrenme tabanlı bir yaprak hastalığı segmentasyon sistemi önerilmektedir. Sistem, yalnızca standart bir akıllı telefon kamerasından elde edilen RGB görüntüleri kullanmakta ve ek donanım gereksinimi olmaksızın hastalıklı bölgeleri piksel düzeyinde tespit edebilmektedir. Ayrıca, RGB görüntülerden pseudo-NIR bant tahmini gerçekleştirilerek modele spektral açıdan zenginleştirilmiş bir girdi sağlanmıştır. Bu yaklaşım sayesinde, özellikle erken evrede ve düşük kontrastlı hastalık bölgelerinin daha başarılı bir şekilde segmentasyonu mümkün hale gelmiştir.

SİMGELER VE KISALTMALAR DİZİNİ

- **AI:** Artificial Intelligence (Yapay Zekâ)
- **CNN:** Convolutional Neural Network
- **FPS:** Frame Per Second
- **IoU:** Intersection over Union
- **NIR:** Near Infrared
- **RGB:** Red Green Blue
- **SAM:** Segment Anything Model
- **TFLite:** TensorFlow Lite

1. GİRİŞ

Dünya genelinde tarım sektörü, artan nüfus ve iklim değişikliği gibi faktörler nedeniyle giderek daha karmaşık bir yapıya bürünmektedir. Bitki hastalıkları, bu karmaşık yapı içerisinde üretim süreçlerini doğrudan etkileyen en önemli unsurlardan biridir. Yaprak hastalıkları, bitkinin temel yaşam fonksiyonlarından biri olan fotosentezi olumsuz etkileyerek ürün verimini ve kalitesini ciddi biçimde düşürmektedir.

Geleneksel tarım uygulamalarında hastalık tespiti çoğunlukla üreticinin deneyimine veya uzmanların saha incelemelerine dayanmaktadır. Ancak bu yaklaşım, geniş tarım alanlarında uygulanabilirlik açısından sınırlıdır. Ayrıca, hastalıkların erken evrede fark edilememesi, kimyasal müdahalelerin gecikmesine ve hastalığın yayılmasına neden olmaktadır.

Son yıllarda yapay zekâ ve bilgisayarlı görü alanındaki hızlı gelişmeler, tarım sektöründe dijital dönüşümün önünü açmıştır. Özellikle evrişimli sinir ağları, görüntü tabanlı analizlerde insan seviyesine yakın hatta bazı durumlarda daha yüksek doğruluklar elde edebilmektedir. Bununla birlikte, literatürde yer alan çalışmaların büyük bir kısmı masaüstü veya sunucu tabanlı sistemler üzerine odaklanmıştır. Mobil cihazlar üzerinde çalışabilen çözümler ise donanım kısıtları nedeniyle sınırlı sayıdadır.

Bu tez çalışması, söz konusu boşluğu doldurmayı hedefleyerek, mobil cihazlarda çalışabilen hafif ve etkili bir yaprak hastalığı segmentasyon sistemi geliştirmeyi amaçlamaktadır.

1.1. Problemin Tanımı ve Önemi

Mevcut yöntemler çoğunlukla uzman gözlemine veya pahalı multispektral donanımlara dayanmaktadır. Küçük ve orta ölçekli üreticiler için bu çözümler erişilebilir değildir. Bu bağlamda, yalnızca RGB kamera kullanan mobil tabanlı bir sistem geliştirmek önemli bir ihtiyaçtır.

1.2. Projenin Kapsamı ve Hedefleri

Bu proje kapsamında:

1. Yaprak görüntülerinin semantik olarak segmentlenmesi,
2. Hastalık şiddetinin yüzdesel olarak hesaplanması,
3. RGB görüntülerden pseudo-NIR bant tahmini yapılması,
4. Mobil cihazlarda gerçek zamanlı çalışabilen bir prototip geliştirilmesi hedeflenmiştir.

1.3. Literatür Özeti

Literatürde bitki hastalığı tespiti üzerine pek çok derin öğrenme tabanlı çalışma bulunmaktadır. Ancak bu çalışmaların büyük bölümü yüksek hesaplama gücü gerektirmekte ve mobil cihazlara uygun değildir. Bu tez, hafif mimariler ve optimizasyon teknikleri ile literatürdeki bu boşluğu doldurmayı amaçlamaktadır.

2. TEKNOLOJİK ALTYAPI VE ARAÇLAR

Bu bölümde, projenin geliştirme sürecinde kullanılan yazılım dilleri, frameworkler ve yardımcı kütüphaneler detaylandırılmıştır.

2.1 Programlama Dilleri ve Frameworkler

- Python: Derin öğrenme ve görüntü işleme süreçleri
- TensorFlow / Keras: Model eğitimi
- Android Studio: Mobil uygulama geliştirme

2.2 Görüntü İşleme ve Yapay Zekâ Kütüphaneleri

- OpenCV
- TensorFlow Lite
- NumPy, Matplotlib

3. KURAMSAL TEMELLER VE YÖNTEM

Bu çalışmada deneysel bir araştırma yöntemi izlenmiştir. Çalışmanın temel amacı, mobil cihazlar üzerinde gerçek zamanlı çalışabilecek bir yaprak hastalığı segmentasyon sistemi geliştirmek ve bu sistemin doğruluk, hız ve mobil uyumluluk açısından performansını değerlendirmektir. Bu doğrultuda veri seti oluşturma, etiketleme, model eğitimi, pseudo-spektral bant üretimi ve mobil optimizasyon aşamaları sırasıyla gerçekleştirilmiştir.

Çalışmanın genel iş akışı; PlantVillage veri setinden seçilen yaprak görüntülerinin etiketlenmesi, veri artırma teknikleri ile veri çeşitliliğinin artırılması, hafifletilmiş UNet tabanlı segmentasyon modelinin eğitilmesi ve eğitilen modelin mobil cihazlarda çalışacak şekilde optimize edilmesi adımlarından oluşmaktadır.

3.1 Veri Seti ve Etiketleme

Bu çalışmada kullanılan veri seti, literatürde yaygın olarak kullanılan PlantVillage veri seti temel alınarak oluşturulmuştur. Veri seti, farklı bitki türlerine ait sağlıklı ve çeşitli hastalık türlerini içeren yaprak görüntülerinden oluşmaktadır. Görüntüler, farklı çözünürlüklerde ve değişken ışık koşullarında elde edilmiştir.

Segmentasyon probleminin gerektirdiği doğrultuda veriler, üç sınıflı semantik etiketleme yaklaşımı ile hazırlanmıştır. Bu sınıflar; sağlıklı yaprak dokusu, hastalıklı bölge ve arka plan olarak belirlenmiştir. Etiketleme işlemi, piksel düzeyinde gerçekleştirilmiş ve her bir görüntü için karşılık gelen maske dosyaları oluşturulmuştur.

Bu yaklaşım sayesinde modelin yalnızca yaprağın hasta olup olmadığını değil, hastalığın yaprak üzerindeki konumunu ve yayılım alanını da öğrenmesi hedeflenmiştir. Etiketleme süreci, segmentasyon doğruluğunu doğrudan etkileyen en kritik aşamalardan biri olduğundan, maskelerin tutarlılığı ve doğruluğu dikkatle kontrol edilmiştir.

3.2 Veri Ön İşleme ve Veri Artırma

Model performansını artırmak ve aşırı öğrenmeyi önlemek amacıyla görüntüler üzerinde çeşitli ön işleme ve veri artırma teknikleri uygulanmıştır. Tüm görüntüler, model giriş boyutuna uygun olacak şekilde yeniden boyutlandırılmış ve piksel değerleri normalize edilmiştir.

Veri artırma aşamasında, döndürme, yatay ve dikey çevirme, parlaklık ve kontrast değişimleri gibi işlemler uygulanmıştır. Bu işlemler sayesinde modelin farklı ışık koşulları ve yaprak pozisyonlarına karşı daha dayanıklı hale gelmesi amaçlanmıştır. Veri artırma teknikleri, özellikle sınırlı veri setlerinde modelin genelleme yeteneğini artırmada önemli bir rol oynamaktadır.

3.3 Model Mimarisi

Bu çalışmada segmentasyon işlemi için hafifletilmiş U-Net tabanlı bir derin öğrenme mimarisi tercih edilmiştir. U-Net mimarisi, encoder–decoder yapısı ve skip connection mekanizması sayesinde hem bağlamsal hem de mekânsal bilgiyi etkili bir şekilde öğrenebilmektedir.

Mobil cihazlarda çalışabilirliği sağlamak amacıyla modelin parametre sayısı azaltılmış, evrişim katmanlarında daha küçük filtreler kullanılmış ve ağ derinliği sınırlı tutulmuştur. Bu sayede model, doğruluk kaybı minimum seviyede tutulurken bellek kullanımı ve çıkarım süresi açısından mobil uyumlu hale getirilmiştir.

Encoder bölümünde, giriş görüntüsünden hiyerarşik özellikler çıkarılırken; decoder bölümünde bu özellikler yeniden uzamsal boyuta taşınarak segmentasyon maskesi üretilmektedir. Skip connection yapıları, düşük seviyeli detayların korunmasını sağlayarak segmentasyon başarımını artırmaktadır.

3.4 Pseudo-Spektral (NIR) Bant Tahmini

Bitki hastalıklarının tespitinde yakın kızılötesi (NIR) bant bilgisinin önemli bir ayırt edici özellik sunduğu bilinmektedir. Ancak NIR görüntü elde etmek için genellikle özel ve maliyetli donanımlar gerekmektedir. Bu çalışmada, ek donanım ihtiyacını ortadan kaldırmak amacıyla pseudo-spektral bant yaklaşımı benimsenmiştir.

Pseudo-NIR bant, RGB kanallar arasındaki istatistiksel ve yapısal ilişkilerden yararlanılarak tahmin edilmiştir. Bu bant, özellikle sağlıklı ve hastalıklı dokular arasındaki yansıtma farklarını daha belirgin hale getirerek segmentasyon modeline ek ayırt edici bilgi sağlamaktadır.

Elde edilen pseudo-NIR bant, RGB görüntüler ile birlikte modele girdi olarak verilmiş ve bu sayede modelin erken evre ve düşük kontrastlı hastalık bölgelerini daha başarılı bir şekilde tespit etmesi sağlanmıştır.

3.5 Mobil Optimizasyon

Eğitilen segmentasyon modelinin mobil cihazlarda etkin bir şekilde çalışabilmesi amacıyla çeşitli optimizasyon teknikleri uygulanmıştır. Model, TensorFlow Lite formatına dönüştürülmüş ve çıkarım süresini azaltmak amacıyla INT8 quantization yöntemi kullanılmıştır.

Kuantizasyon sürecinde, model ağırlıkları ve aktivasyonları daha düşük bit hassasiyetine indirgenmiş, bu sayede model boyutu önemli ölçüde küçültülmüştür. Bu işlem sonucunda bellek kullanımı azalırken, mobil cihazlarda daha hızlı çıkarım elde edilmiştir.

Mobil testler Android tabanlı cihazlar üzerinde gerçekleştirilmiş ve sistemin gerçek zamanlı çalışabilirliği değerlendirilmiştir. Optimizasyon sonrası elde edilen sonuçlar, doğruluk kaybının kabul edilebilir sınırlar içerisinde kaldığını ve sistemin mobil kullanım için uygun olduğunu göstermiştir.

3.6 Deneyisel Sonuçlar ve Performans Analizi

Bu bölümde, geliştirilen yaprak hastalığı segmentasyon sisteminin son optimizasyonlar sonrası elde edilen doğruluk, hız ve mobil cihaz verimliliği değerleri ayrıntılı olarak sunulmaktadır. Yapılan çalışmalar neticesinde, modelin hem teorik başarımı hem de saha uygulama performansı önemli ölçüde geliştirilmiştir.

3.6.1 Değerlendirme Metrikleri

Sistemin segmentasyon hassasiyetini ve gerçek zamanlı çalışma kapasitesini ölçmek amacıyla; Intersection over Union (IoU), Mean IoU (mIoU), Dice Katsayısı, Kare Saniye Hızı (FPS) ve Çıkarım (Inference) Süresi metrikleri temel alınmıştır.

3.6.2 Eğitim ve Test Sonuçları

Model, PlantVillage veri setinden seçilen ve veri artırma (data augmentation) yöntemleriyle zenginleştirilen yaklaşık 3014 adet etiketli yaprak görüntüsü ile eğitilmiştir. Eğitim sürecinde uygulanan hiperparametre optimizasyonları ve "Learning Rate Scheduler" kullanımı sonucunda, test veri seti üzerinde %79,5 mIoU ve %88,2 Dice katsayısı elde edilmiştir. Bu sonuçlar, ilk aşamadaki prototip modelin başarımının yaklaşık %3-4 oranında artırıldığını göstermektedir.

3.6.3 Pseudo-NIR Bant Katkısının Analizi

Pseudo-NIR (sahte kızılötesi) bant üretiminin segmentasyon üzerindeki etkisi, farklı ışık koşullarında (doğrudan güneş ışığı, gölge ve iç mekan) test edilmiştir. Analizler sonucunda, Pseudo-NIR destekli modelin, özellikle yaprak üzerindeki damar yapılarının ve lezyon sınırlarının belirlenmesinde standart RGB modellere göre daha kararlı sonuçlar verdiği saptanmıştır. Pseudo-NIR kullanımı, segmentasyon doğruluğunda %3-5 oranında bir iyileşme sağlamış, ışık patlamalarından kaynaklanan hataları minimize etmiştir.

3.6.4 Mobil Performans ve Optimizasyon Sonuçları

Eğitilen modelin mobil cihazlarda (Android) akıcı çalışabilmesi için INT8 Quantization teknikleri uygulanmıştır. Yapılan optimizasyonlar sonucunda;

Çıkarım Süresi: Ortalama 45-55 ms seviyesine indirilmiştir.

Kare Hızı (FPS): Mobil cihazlarda gerçek zamanlı takip için kritik eşik olan 15-18 FPS değerlerine ulaşılmıştır.

Güç Tüketimi: GPU hızlandırma desteği ile CPU üzerindeki yük azaltılmış, böylece uzun süreli saha kullanımlarında cihaz ısınma sorunu optimize edilmiştir.

4. TASARIM VE UYGULAMA

Bu bölümde, geliştirilen mobil yaprak hastalığı tespit uygulamasının sistem mimarisi, mobil platforma entegrasyonu, gerçek zamanlı görüntü işleme süreci ve kullanıcı arayüzü tasarımı ayrıntılı olarak açıklanmaktadır. Sistem, tamamen mobil cihaz üzerinde (on-device) çalışacak şekilde tasarlanmış olup herhangi bir sunucu veya bulut tabanlı işlem gereksinimi bulunmamaktadır. Bu yaklaşım, düşük gecikme süresi, veri gizliliği ve saha koşullarında kesintisiz kullanım açısından önemli avantajlar sağlamaktadır.

4.1 Sistem Mimarisi ve Genel İş Akışı

Geliştirilen sistem, Android işletim sistemi üzerinde çalışan çok katmanlı bir mobil uygulama mimarisine sahiptir. Sistem mimarisi; kullanıcı arayüzü katmanı, görüntü edinim ve ön işleme katmanı, makine öğrenmesi çıkarım (inference) katmanı ve sonuç görselleştirme katmanlarından oluşmaktadır.

Genel iş akışı aşağıdaki adımlardan oluşmaktadır:

Android Kamera API → Görüntü Ön İşleme → TensorFlow Lite Segmentasyon Modeli → Pseudo-Spektral Analiz → Sonuç Görselleştirme

Kullanıcı tarafından kamera aracılığıyla elde edilen görüntüler, gerçek zamanlı olarak uygulama içerisinde işlenmekte ve segmentasyon modeli tarafından analiz edilmektedir. Tüm bu işlemler mobil cihaz üzerinde gerçekleştirilmektedir.

4.2 Mobil Görüntü Edinimi ve Ön İşleme Süreci

Mobil uygulamada görüntü edinimi, Android CameraX API kullanılarak gerçekleştirilmiştir. CameraX, farklı donanım yapılarına sahip cihazlarda tutarlı performans sunması nedeniyle tercih edilmiştir. Kamera akışından alınan görüntüler, belirli aralıklarla işlenerek modele beslenmektedir.

Elde edilen görüntüler üzerinde yeniden boyutlandırma, normalizasyon ve renk uzayı düzenlemeleri gibi ön işleme adımları uygulanmaktadır. Bu işlemler, modelin eğitim

aşamasında kullanılan veri formatı ile uyumluluğu sağlamak amacıyla gerçekleştirilmiştir. Ön işleme süreci, gerçek zamanlı çalışmayı engellemeyecek şekilde optimize edilmiştir.

4.3 TensorFlow Lite Model Entegrasyonu

Eğitilen hafifletilmiş U-Net tabanlı segmentasyon modeli, TensorFlow Lite formatına dönüştürülerek mobil uygulamaya entegre edilmiştir. Model entegrasyonu sırasında TensorFlow Lite Interpreter kullanılmış ve INT8 quantization uygulanmış model tercih edilmiştir.

Bu sayede modelin bellek kullanımı azaltılmış ve çıkarım süresi kısaltılmıştır. Mobil cihaz üzerinde yapılan testlerde model, gerçek zamanlı çalışabilecek performans seviyesine ulaşmıştır. Model çıktısı, her bir piksel için sınıf olasılıklarını içeren bir segmentasyon maskesi şeklinde elde edilmektedir.

4.4 Gerçek Zamanlı Segmentasyon ve Pseudo-Spektral Analiz

Segmentasyon modeli tarafından üretilen maske, uygulama içerisinde anlık olarak işlenmekte ve orijinal kamera görüntüsü üzerine bindirilerek kullanıcıya sunulmaktadır. Bu görselleştirme, yarı saydam renk katmanları kullanılarak gerçekleştirilmiştir.

Ayrıca RGB görüntülerden tahmin edilen pseudo-spektral (NIR benzeri) bant, segmentasyon sürecini desteklemek amacıyla kullanılmaktadır. Bu bant sayesinde, düşük kontrastlı veya erken evre hastalık belirtilerinin daha belirgin hale getirilmesi sağlanmıştır. Pseudo-spektral analiz, mobil cihazın hesaplama kapasitesini zorlamayacak şekilde optimize edilmiştir.

4.5 Kullanıcı Arayüzü Tasarımı ve Kullanıcı Deneyimi (UX)

Mobil uygulamanın kullanıcı arayüzü, Android platformunun modern tasarım dili olan Material Design 3 standartlarına sadık kalınarak, teknik bilgisi kısıtlı son kullanıcıların (çiftçiler, ziraat mühendisleri) dahi zorlanmadan kullanabileceği sezgisel bir yapıda geliştirilmiştir. Tasarımda şu temel bileşenler ön plana çıkarılmıştır:

Gerçek Zamanlı Görselleştirme (Live Overlay): Kamera vizörü üzerinde, yapay zeka modelinden gelen segmentasyon maskesi düşük gecikme süresiyle bir katman (overlay) olarak sunulmaktadır. Hastalıklı bölgeler, kullanıcıya net bir görsel geri bildirim sağlamak amacıyla yüksek kontrastlı renklerle vurgulanmaktadır.

Dinamik Karar Destek Paneli: Analiz sırasında ekranın alt kısmında yer alan panelde; toplam yaprak alanı, hastalıklı bölge yüzdesi ve segmentasyonun güven skoru (confidence score) eş zamanlı olarak güncellenmektedir. Hastalık oranına göre arayüz, kullanıcıyı uyaran renk skalasına (yeşil-sarı-kırmızı) sahiptir.

Geçmiş Analiz ve Veri Yönetimi: Uygulama, SQLite tabanlı yerel bir veritabanı ile entegre edilmiştir. Kullanıcılar yaptıkları analizleri tarih, saat ve (isteğe bağlı) konum bilgisiyle kaydedebilmekte, böylece hastalığın zamana bağlı ilerleyişini geçmişe dönük olarak karşılaştırabilmektedir.

Saha Koşullarına Uygunluk: Tarım arazilerindeki yoğun ışık altında okunabilirliği artırmak adına yüksek kontrastlı yazı tipleri ve ikonlar tercih edilmiştir. Ayrıca uygulamanın tamamen **çevrimdışı (offline)** çalışma özelliği sayesinde, internet erişiminin olmadığı kırsal alanlarda dahi kesintisiz analiz imkânı sağlanmıştır.

4.6 Mobil Performans ve Kaynak Kullanımı Değerlendirmesi

Geliştirilen sistemin mobil performansı, farklı Android cihazlar üzerinde test edilmiştir. Yapılan ölçümlerde uygulamanın saniyede ortalama 15–18 kare işleyebildiği gözlemlenmiştir. Bellek kullanımı ve işlemci yükü mobil cihaz sınırları içerisinde kalmıştır.

Bu sonuçlar, geliştirilen uygulamanın gerçek saha koşullarında uzun süreli kullanım için uygun olduğunu göstermektedir.

5. SONUÇ VE DEĞERLENDİRME

Bu bölümde, geliştirilen mobil yaprak hastalığı tespit sisteminin mevcut durumu özetlenmekte ve çalışmanın kapsamı doğrultusunda elde edilen bulgular

değerlendirilmektedir. Ayrıca, ilerleyen aşamalarda gerçekleştirilebilecek olası geliştirme ve iyileştirme çalışmaları ele alınmaktadır.

5.1 Mevcut Durum Analizi

Bu bitirme tezi kapsamında, mobil cihazlar üzerinde gerçek zamanlı çalışabilen yaprak hastalığı segmentasyon ve analiz sistemi başarıyla geliştirilmiştir. Android işletim sistemi üzerinde çalışan uygulama, kamera girdisini doğrudan alarak TensorFlow Lite tabanlı derin öğrenme modeli ile analiz edebilmektedir. Geliştirilen sistemde, hafifletilmiş U-Net mimarisi kullanılarak yaprak üzerindeki hastalıklı bölgeler piksel düzeyinde tespit edilmiştir. Uygulanan INT8 quantization ve TensorFlow Lite optimizasyonları sayesinde model, mobil cihazlarda kabul edilebilir doğruluk değerleri ile gerçek zamanlı çalışabilir hale getirilmiştir. Yapılan deneysel değerlendirmelerde sistemin saniyede ortalama 15–18 kare işleyebildiği ve mobil donanım kısıtları içerisinde stabil bir performans sergilediği gözlemlenmiştir. Ayrıca, RGB görüntülerden tahmin edilen pseudo-spektral (NIR benzeri) bant kullanımı sayesinde, özellikle erken evre ve düşük kontrastlı hastalık belirtilerinin tespitinde performans artışı sağlanmıştır. Bu durum, geliştirilen yaklaşımın pratik tarım uygulamaları açısından potansiyelini ortaya koymaktadır.

5.2 Gelecek Çalışmalar ve Planlanan Geliştirmeler

Projenin mevcut aşamasında elde edilen başarılı segmentasyon sonuçları ve mobil çalışma performansı, sistemin ticari ve akademik potansiyelini ortaya koymuştur. Çalışmanın gelecek evrelerinde hedeflenen geliştirme faaliyetleri şunlardır:

Bulut Entegrasyonu ve Büyük Veri Analizi: Analiz edilen hastalık verilerinin anonimleştirilerek merkezi bir bulut sunucusuna aktarılması ve bölge bazlı "hastalık yayılım haritaları" oluşturulması planlanmaktadır. Bu sayede tarımsal salgınların önceden tahmini mümkün olacaktır.

Akıllı Öneri Sistemi (Karar Destek): Sistemin sadece hastalığı tespit etmekle kalmayıp; bitki türüne, hastalığın evresine ve çevre koşullarına göre kullanıcıya spesifik ilaçlama veya bakım önerileri sunan bir uzman sistem haline getirilmesi hedeflenmektedir.

Multimodal Veri Füzyonu: Görüntü verilerine ek olarak, mobil cihazın sensörleri veya harici IoT cihazları aracılığıyla alınan sıcaklık ve nem gibi çevresel verilerin model girişine dahil edilmesiyle, teşhis doğruluğunun maksimize edilmesi amaçlanmaktadır.

Gelişmiş Model Sıkıştırma Teknikleri: Mevcut TFLite modelinin INT8 **Quantization** ve **Pruning** (budama) yöntemleriyle daha da küçültülerek, çok düşük donanım özelliklerine sahip giriş seviyesi mobil cihazlarda dahi yüksek performansla çalışması sağlanacaktır.

iOS Platformu ve Web Desteği: Şu an Android tabanlı olan uygulamanın, Cross-Platform (Flutter veya React Native) teknolojileri kullanılarak iOS ve web tarayıcıları üzerinden de erişilebilir hale getirilmesi planlanmaktadır.

Otonom İHA Entegrasyonu: Mobil uygulamanın sunduğu segmentasyon algoritmasının insansız hava araçlarına (İHA) entegre edilerek, geniş tarım arazilerinin otonom olarak taranması ve hastalık tespitinin havadan yapılması uzun vadeli hedefler arasındadır.

KAYNAKLAR

- [1] Barbedo, J. G. A. (2019). Plant disease identification from individual lesions using deep learning. *Computers and Electronics in Agriculture*, 167, 105250.
- [2] Polder, G., van der Heijden, G., Young, I., & van Vliet, L. J. (2020). Measuring and detecting chlorophyll fluorescence using RGB and nearinfrared imaging for early plant disease diagnosis. *Precision Agriculture*, 21(6), 1201–1218.
- [3] Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419.

- [4] Lamaka, P., Hakala, T., Khoroshiltseva, M., & Hautamäki, V. (2023). Lightweight deep learning models for mobile plant disease segmentation and real-time edge deployment. *Sensors*, 23(4), 1908.

ÖZGEÇMİŞ

Kişisel Bilgiler

- **Adı Soyadı:** Hazan Ezgi Erçin
- **Doğum Yeri ve Tarihi:** Zonguldak / Ereğli, 05.07.2001

Eğitim Durumu

- **Lisans:** Bandırma Onyedi Eylül Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2023-2026.
- **Lisans:** Antalya Bilim Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2022-2023.
- **Lisans:** İstinye Üniversitesi, Mühendislik ve Doğa

Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2020-2022.

- **Lise:** Özel Kampüs Temel Lisesi, 2017-2019.

İlgi Alanları □ Görüntü İşleme

- **Web Uygulama Geliştirme** (Full-stack Development)
- **Makine Öğrenmesi ve Yapay Zeka □ Medikal/Sağlık Yazılım Çözümleri Diller □ Türkçe:** Ana Dil
- **İngilizce:** İyi Seviye (B2)
- **Almanca:** Başlangıç Seviyesi (A2)

ÖZGEÇMİŞ

Kişisel Bilgiler

- **Adı Soyadı:** Fatih Taşkın
- **Doğum Yeri ve Tarihi:** İstanbul / Kartal, 04.08.2001

Eğitim Durumu

- **Lisans:** Bandırma Onyedi Eylül Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2021-2026.
- **Lise:** Atilla Uras Anadolu Lisesi- Maltepe/İstanbul, 2015-2019.
- **Ortaokul:** Ercan Görür İlköğretim Okulu- Pendik/İstanbul, 2008-2015

İlgi Alanları □ Görüntü İşleme (Computer Vision)

- **Web Uygulama Geliştirme** (Full-stack Development)
- **Makine Öğrenmesi ve Yapay Zeka □ Veri, Performans ve Sistem Analizi Diller □ Türkçe:** Ana Dil
- **İngilizce:** İyi Seviye (B2)