

T.C.
BANDIRMA ONYEDİ EYLÜL ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ



LİSANS BİTİRME PROJESİ

PROJE BAŞLIĞI

MOBİL CİHAZLARDA GERÇEK ZAMANLI YAPRAK HASTALIĞI
SEGMENTASYONU VE PSEUDO-SPEKTRAL ANALİZ TABANLI KARAR
DESTEK SİSTEMİ

Fatih Taşkın
2111504031
Hazan Ezgi Erçin
2311504299

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Dr. Öğr. Üyesi Alpay Doruk
HAZİRAN 2026

İÇİNDEKİLER

ÖZET	3
SİMGELER VE KISALTMALAR LİSTESİ	4
1. GİRİŞ	5
1.1. Problemin Tanımı ve Önemi	6
1.2. Projenin Kapsamı ve Hedefleri	6
1.3. Literatür Özeti	6
2. TEKNOLOJİK ALTYAPI VE ARAÇLAR.....	7
2.1. Programlama Dilleri ve Frameworkler	7
2.2. Görüntü İşleme ve Yapay Zeka Kütüphaneleri	7
3. KURAMSAL TEMELLER VE YÖNTEM.....	8
3.1. Veri Seti ve Etiketleme.....	8-9
3.2. Veri Ön İşleme ve Veri Artırma.....	10
3.3. Model Mimarisi	10-11
3.4. Pseudo-Spektral (NIR) Bant Tahmini.....	12
3.5. Mobil Optimizasyon	12
3.6. Deneysel Sonuçlar ve Performans Analizi	13
3.6.1 Değerlendirme Metrikleri.....	13
3.6.2 Eğitim ve Test Sonuçları.....	13
3.6.3 Pseudo-NIR Bant Katkısının Analizi.....	13
3.6.4 Mobil Performans Sonuçları	13
4. TASARIM VE UYGULAMA	14
4.1. Sistem Mimarisi ve Genel İş Akışı.....	14
4.2. Mobil Görüntü Edinimi ve Ön İşleme Süreci	15
4.3. TensorFlow Lite Model Entegrasyonu.....	15
4.4. Gerçek Zamanlı Segmentasyon ve Pseudo-Spektral Analiz	16

4.5. Kullanıcı Arayüzü Tasarımı	16
4.6. Mobil Performans ve Kaynak Kullanımı Değerlendirmesi	17
5. SONUÇ VE DEĞERLENDİRME	18
5.1. Mevcut Durum Analizi	18-19
5.2. Gelecek Çalışmalar ve Planlanan Geliştirmeler	20
KAYNAKLAR	21
ÖZGEÇMİŞ.....	22-23

ÖZET

Tarımsal üretimde karşılaşılan bitki hastalıkları, yalnızca ürün miktarını değil aynı zamanda ürün kalitesini de olumsuz yönde etkilemektedir. Özellikle yaprak üzerinde oluşan fungal, bakteriyel ve viral kaynaklı hastalıklar, fotosentez mekanizmasını doğrudan etkileyerek bitkinin gelişim sürecini sekteye uğratmaktadır. Bu durum, hem küçük ölçekli üreticiler hem de endüstriyel tarım uygulamaları açısından ciddi ekonomik kayıplara neden olmaktadır.

Geleneksel hastalık tespit süreçleri, çoğunlukla saha gözlemi ve uzman değerlendirmesine dayalıdır. Bu yöntemler, yüksek doğruluk sağlayabilmesine rağmen zaman alıcı olmaları, insan hatasına açık olmaları ve her bölgede uzman erişiminin mümkün olmaması gibi dezavantajlara sahiptir. Bu bağlamda, otomatik ve taşınabilir karar destek sistemlerine olan ihtiyaç her geçen gün artmaktadır.

Bu tez çalışmasında, mobil cihazlar üzerinde gerçek zamanlı olarak çalışabilen, derin öğrenme tabanlı bir yaprak hastalığı segmentasyon sistemi önerilmektedir. Sistem, yalnızca standart bir akıllı telefon kamerasından elde edilen RGB görüntüleri kullanmakta ve ek donanım gereksinimi olmaksızın hastalıklı bölgeleri piksel düzeyinde tespit edebilmektedir. Ayrıca, RGB görüntülerden pseudo-NIR bant tahmini gerçekleştirilerek modele spektral açıdan zenginleştirilmiş bir girdi sağlanmıştır. Bu yaklaşım sayesinde, özellikle erken evrede ve düşük kontrastlı hastalık bölgelerinin daha başarılı bir şekilde segmentasyonu mümkün hale gelmiştir.

SİMGELELER VE KISALTMALAR DİZİNİ

- **AI:** Artificial Intelligence (Yapay Zekâ)
- **CNN:** Convolutional Neural Network
- **FPS:** Frame Per Second
- **IoU:** Intersection over Union
- **NIR:** Near Infrared
- **RGB:** Red Green Blue
- **SAM:** Segment Anything Model
- **TFLite:** TensorFlow Lite

1.GİRİŞ

Dünya genelinde tarım sektörü, artan nüfus ve iklim değişikliği gibi faktörler nedeniyle giderek daha karmaşık bir yapıya bürünmektedir. Bitki hastalıkları, bu karmaşık yapı içerisinde üretim süreçlerini doğrudan etkileyen en önemli unsurlardan biridir. Yaprak hastalıkları, bitkinin temel yaşam fonksiyonlarından biri olan fotosentezi olumsuz etkileyerek ürün verimini ve kalitesini ciddi biçimde düşürmektedir.

Geleneksel tarım uygulamalarında hastalık tespiti çoğunlukla üreticinin deneyimine veya uzmanların saha incelemelerine dayanmaktadır. Ancak bu yaklaşım, geniş tarım alanlarında uygulanabilirlik açısından sınırlıdır. Ayrıca, hastalıkların erken evrede fark edilememesi, kimyasal müdahalelerin gecikmesine ve hastalığın yayılmasına neden olmaktadır.

Son yıllarda yapay zekâ ve bilgisayarlı görü alanındaki hızlı gelişmeler, tarım sektöründe dijital dönüşümün önünü açmıştır. Özellikle evrişimli sinir ağları, görüntü tabanlı analizlerde insan seviyesine yakın hatta bazı durumlarda daha yüksek doğruluklar elde edebilmektedir. Bununla birlikte, literatürde yer alan çalışmaların büyük bir kısmı masaüstü veya sunucu tabanlı sistemler üzerine odaklanmıştır. Mobil cihazlar üzerinde çalışabilen çözümler ise donanım kısıtları nedeniyle sınırlı sayıdadır.

Bu tez çalışması, söz konusu boşluğu doldurmayı hedefleyerek, mobil cihazlarda çalışabilen hafif ve etkili bir yaprak hastalığı segmentasyon sistemi geliştirmeyi amaçlamaktadır.

1.1. Problemin Tanımı ve Önemi

Mevcut yöntemler çoğunlukla uzman gözlemine veya pahalı multispektral donanımlara dayanmaktadır. Küçük ve orta ölçekli üreticiler için bu çözümler erişilebilir değildir. Bu bağlamda, yalnızca RGB kamera kullanan mobil tabanlı bir sistem geliştirmek önemli bir ihtiyaçtır.

1.2. Projenin Kapsamı ve Hedefleri

Bu proje kapsamında:

1. Yaprak görüntülerinin semantik olarak segmentlenmesi,
2. Hastalık şiddetinin yüzdesel olarak hesaplanması,
3. RGB görüntülerden pseudo-NIR bant tahmini yapılması,
4. Mobil cihazlarda gerçek zamanlı çalışabilen bir prototip geliştirilmesi hedeflenmiştir.

1.3. Literatür Özeti

Literatürde bitki hastalığı tespiti üzerine pek çok derin öğrenme tabanlı çalışma bulunmaktadır. Mohanty vd. [3], PlantVillage veri setini kullanarak eğittikleri evrişimli sinir ağı ile %99,35 doğruluk elde etmiş, ancak çalışmaları yaprak düzeyinde sınıflandırmayla sınırlı kalmış ve piksel düzeyinde segmentasyon içermemiştir. Barbedo [1], hastalığı bütün yaprak yerine bireysel lezyon ve lekeler düzeyinde tespit ederek daha ayrıntılı bir yaklaşım sunmuş, ancak bu çalışma mobil platformlarda gerçek zamanlı çalışabilirliği hedeflememiştir. Zhang vd. [2], RGB görüntülerden hiperspektral/NIR bant geri çatımı (spectral reconstruction) üzerine kapsamlı bir derleme sunarak, ek donanım gerektirmeyen spektral genişletme yaklaşımlarının fizibilitesini ortaya koymuş; bu çalışma, tez kapsamında benimsenen pseudo-NIR yaklaşımı için kuramsal bir temel oluşturmaktadır. Nnamdi ve Abolghasemi [4] ise mobil cihazlarda çalışabilen hafifletilmiş bir MobileNet mimarisi önererek yalnızca 1,46 MB boyutunda bir model ile %97-98 doğruluk elde etmiş, ancak bu çalışma da sınıflandırma görevine odaklanmış, segmentasyon ve spektral zenginleştirme içermemiştir. Bu çalışmaların büyük bölümü yüksek hesaplama gücü gerektirmekte veya yalnızca sınıflandırma düzeyinde kalmaktadır. Bu tez, hafif mimariler ve optimizasyon teknikleri ile literatürdeki bu boşluğu doldurmayı amaçlamaktadır.

2. TEKNOLOJİK ALTYAPI VE ARAÇLAR

Bu bölümde, projenin geliştirme sürecinde kullanılan yazılım dilleri, frameworkler ve yardımcı kütüphaneler detaylandırılmıştır.

2.1 Programlama Dilleri ve Frameworkler

- Python: Derin öğrenme ve görüntü işleme süreçleri
- TensorFlow / Keras: Model eğitimi
- Android Studio: Mobil uygulama geliştirme

2.2 Görüntü İşleme ve Yapay Zekâ Kütüphaneleri

- OpenCV
- TensorFlow Lite
- NumPy, Matplotlib

3. KURAMSAL TEMELLER VE YÖNTEM

Bu çalışmada deneysel bir araştırma yöntemi izlenmiştir. Çalışmanın temel amacı, mobil cihazlar üzerinde gerçek zamanlı çalışabilecek bir yaprak hastalığı segmentasyon sistemi geliştirmek ve bu sistemin doğruluk, hız ve mobil uyumluluk açısından performansını değerlendirmektir. Bu doğrultuda veri seti oluşturma, etiketleme, model eğitimi, pseudo-spektral bant üretimi ve mobil optimizasyon aşamaları sırasıyla gerçekleştirilmiştir.

Çalışmanın genel iş akışı; PlantVillage veri setinden seçilen yaprak görüntülerinin etiketlenmesi, veri artırma teknikleri ile veri çeşitliliğinin artırılması, hafifletilmiş U-Net tabanlı segmentasyon modelinin eğitilmesi ve eğitilen modelin mobil cihazlarda çalışacak şekilde optimize edilmesi adımlarından oluşmaktadır.

3.1 Veri Seti ve Etiketleme

Bu çalışmada kullanılan veri seti, literatürde yaygın olarak kullanılan PlantVillage veri seti [6] temel alınarak oluşturulmuştur. Veri seti, farklı bitki türlerine ait sağlıklı ve çeşitli hastalık türlerini içeren yaprak görüntülerinden oluşmaktadır. Görüntüler, farklı çözünürlüklerde ve değişken ışık koşullarında elde edilmiştir.

Segmentasyon probleminin gerektirdiği doğrultuda veriler, üç sınıflı semantik etiketleme yaklaşımı ile hazırlanmıştır. Bu sınıflar; sağlıklı yaprak dokusu, hastalıklı bölge ve arka plan olarak belirlenmiştir. Etiketleme işlemi, piksel düzeyinde gerçekleştirilmiş ve her bir görüntü için karşılık gelen maske dosyaları oluşturulmuştur.

Bu yaklaşım sayesinde modelin yalnızca yaprağın hasta olup olmadığını değil, hastalığın yaprak üzerindeki konumunu ve yayılım alanını da öğrenmesi hedeflenmiştir. Etiketleme süreci, segmentasyon doğruluğunu doğrudan etkileyen en kritik aşamalardan biri olduğundan, maskelerin tutarlılığı ve doğruluğu dikkatle kontrol edilmiştir.

Araştırma önerisinde planlanan dördüncü sınıf (damar/doğal yapı), etiketleme aşamasında sağlıklı doku ile yüksek oranda örtüşmesi ve anotasyon tutarlılığını düşürmesi nedeniyle sağlıklı yaprak dokusu sınıfı ile birleştirilmiş; bu doğrultuda üç sınıflı (arka plan, sağlıklı doku, hastalıklı bölge) bir etiketleme şemasına karar verilmiştir.

Tablo 3.1: Veri artırma sonrası kategori bazında görüntü sayıları.

Kategori	Görüntü Sayısı
Elma	1006
Mısır	1000
Üzüm	1008
Toplam	3014

3.2 Veri Ön İşleme ve Veri Artırma

Model performansını artırmak ve aşırı öğrenmeyi önlemek amacıyla görüntüler üzerinde çeşitli ön işleme ve veri artırma teknikleri uygulanmıştır. Tüm görüntüler, model giriş boyutuna uygun olacak şekilde yeniden boyutlandırılmış ve piksel değerleri normalize edilmiştir.


Veri artırma aşamasında, döndürme, yatay ve dikey çevirme, parlaklık ve kontrast değişimleri gibi işlemler uygulanmıştır. Bu işlemler sayesinde modelin farklı ışık koşulları ve yaprak pozisyonlarına karşı daha dayanıklı hale gelmesi amaçlanmıştır. Veri artırma teknikleri, özellikle sınırlı veri setlerinde modelin genelleme yeteneğini artırmada önemli bir rol oynamaktadır.

3.3 Model Mimarisi

Bu çalışmada segmentasyon işlemi için hafifletilmiş U-Net [5] tabanlı bir derin öğrenme mimarisi tercih edilmiştir. U-Net mimarisi, encoder–decoder yapısı ve skip connection mekanizması sayesinde hem bağlamsal hem de mekânsal bilgiyi etkili bir şekilde öğrenebilmektedir.

Mobil cihazlarda çalışabilirliği sağlamak amacıyla modelin parametre sayısı azaltılmış, evrişim katmanlarında daha küçük filtreler kullanılmış ve ağ derinliği sınırlı tutulmuştur. Bu sayede model, doğruluk kaybı minimum seviyede tutulurken bellek kullanımı ve çıkarım süresi açısından mobil uyumlu hale getirilmiştir.

Encoder bölümünde, giriş görüntüsünden hiyerarşik özellikler çıkarılırken; decoder bölümünde bu özellikler yeniden uzamsal boyuta taşınarak segmentasyon maskesi üretilmektedir. Skip connection yapıları, düşük seviyeli detayların korunmasını sağlayarak segmentasyon başarımını artırmaktadır.



Şekil 3.1: Hafifletilmiş U-Net mimarisi (encoder-decoder ve skip connection yapısı).

3.4 Pseudo-Spektral (NIR) Bant Tahmini

Bitki hastalıklarının tespitinde yakın kızılötesi (NIR) bant bilgisinin önemli bir ayırt edici özellik sunduğu bilinmektedir. Ancak NIR görüntü elde etmek için genellikle özel ve maliyetli donanımlar gerekmektedir. Bu çalışmada, ek donanım ihtiyacını ortadan kaldırmak amacıyla pseudo-spektral bant yaklaşımı benimsenmiştir.

Pseudo-NIR bant, RGB kanallar arasındaki istatistiksel ve yapısal ilişkilerden yararlanılarak tahmin edilmiştir. Bu bant, özellikle sağlıklı ve hastalıklı dokular arasındaki yansıtma farklarını daha belirgin hale getirerek segmentasyon modeline ek ayırt edici bilgi sağlamaktadır.

Elde edilen pseudo-NIR bant, RGB görüntüler ile birlikte modele girdi olarak verilmiş ve bu sayede modelin erken evre ve düşük kontrastlı hastalık bölgelerini daha başarılı bir şekilde tespit etmesi sağlanmıştır.

3.5 Mobil Optimizasyon

Model, veri artırma sonrasında toplam 3014 etiketli yaprak görüntüsü (elma: 1006, mısır: 1000, üzüm: 1008) ile yeniden eğitilmiştir. Test veri seti üzerinde %79,5 mIoU ve %88,2 Dice katsayısı elde edilmiştir. Kategori bazında: elma %74,1 IoU / %84,6 Dice, mısır %85,6 IoU / %92,1 Dice, üzüm %79,0 IoU / %88,0 Dice. Başlangıçta mısır kategorisinde yalnızca 264 görüntü bulunması ve maskelerin otomatik HSV yöntemiyle üretilmesi nedeniyle ilk tahminler gerçeği yansıtmamaktaydı. Veri artırma ile mısır 1000 görüntüye çıkartılmış ve model yeniden eğitilmiştir.

Kuantizasyon sürecinde model ağırlıkları INT8 hassasiyetine indirgenmiş, bu sayede model boyutu önemli ölçüde küçültülmüştür. Bu işlem sonucunda segmentasyon modeli 741 KB boyutundaki orijinal (.h5) halinden 71 KB'lık bir .tflite dosyasına, pseudo-NIR modeli ise 1793 KB boyutundan 158 KB'lık bir .tflite dosyasına indirilmiştir; toplam mobil model boyutu (~229 KB) TÜBİTAK 2209-A önerisinde hedeflenen 10 MB sınırının büyük ölçüde altında kalmıştır. Bu işlem sonucunda bellek kullanımı azalırken, mobil cihazlarda daha hızlı çıkarım elde edilmiştir.

Mobil performans testleri, gerçek bir Android cihaza erişim kısıtı nedeniyle Android Emülatörü üzerinde (PC: Intel Core i7-11800H, 16 GB RAM, Windows 11) gerçekleştirilmiş ve sistemin gerçek zamanlı çalışabilirliği bu ortamda değerlendirilmiştir. Optimizasyon sonrası elde edilen sonuçlar, doğruluk kaybının kabul edilebilir sınırlar içerisinde kaldığını ve sistemin mobil kullanım için uygun olduğunu göstermiştir; gerçek mobil donanımda doğrulama testleri gelecek çalışmalar kapsamında planlanmaktadır.

3.6 Deneysel Sonuçlar ve Performans Analizi

Bu bölümde geliştirilen yaprak hastalığı segmentasyon sisteminin doğruluk, hız ve mobil cihaz uyumluluğu açısından elde edilen deneysel sonuçları ayrıntılı biçimde sunulmaktadır. Deneyler hem masaüstü geliştirme ortamında hem de Android Emülatörü üzerinde gerçekleştirilmiştir; gerçek bir mobil cihaza erişim kısıtı nedeniyle fiziksel donanımda doğrulama yapılamamıştır.

3.6.1 Değerlendirme Metrikleri

Segmentasyon performansının nicel olarak değerlendirilmesi için Intersection over Union (IoU), Mean IoU (mIoU), Dice katsayısı, FPS ve çıkarım süresi metrikleri kullanılmıştır.

3.6.2 Eğitim ve Test Sonuçları

Model, yaklaşık 3014adet etiketli yaprak görüntüsü ile eğitilmiş ve test veri seti üzerinde %79,5 mIoU ve %88,2 Dice katsayısı elde edilmiştir.

3.6.3 Pseudo-NIR Bant Katkısının Analizi

Pseudo-NIR destekli modelin, yalnızca RGB kullanan modele kıyasla %3-5 oranında performans artışı sağladığı gözlemlenmiştir. Özellikle erken evre ve düşük kontrastlı hastalık bölgelerinin tespitinde bu katkının daha belirgin olduğu görülmüştür. Bu değerlendirme, pseudo-NIR bandının segmentasyon doğruluğuna olan dolaylı etkisi üzerinden yapılmıştır; bandın kendi spektral kalitesini doğrudan ölçen SSIM tabanlı bir karşılaştırma bu aşamada gerçekleştirilmemiş olup gelecek çalışmalar kapsamında planlanmaktadır.

3.6.4 Mobil Performans Sonuçları

Model, Android Emülatöründe (PC: Intel Core i7-11800H, 16 GB RAM) 15-18 FPS hızında çalışabilmiş ve gerçek zamanlı kullanım için yeterli performans sunmuştur. Bu rakamların gerçek mobil donanımdaki (daha sınırlı RAM, ARM işlemci, termal kısıtlar) karşılığı bu çalışma kapsamında doğrulanmamıştır.

4. TASARIM VE UYGULAMA


Bu bölümde, geliştirilen mobil yaprak hastalığı tespit uygulamasının sistem mimarisi, mobil platforma entegrasyonu, gerçek zamanlı görüntü işleme süreci ve kullanıcı arayüzü tasarımı ayrıntılı olarak açıklanmaktadır. Sistem, tamamen mobil cihaz üzerinde (on-device) çalışacak şekilde tasarlanmış olup herhangi bir sunucu veya bulut tabanlı işlem gereksinimi bulunmamaktadır. Bu yaklaşım, düşük gecikme süresi, veri gizliliği ve saha koşullarında kesintisiz kullanım açısından önemli avantajlar sağlamaktadır.

4.1 Sistem Mimarisi ve Genel İş Akışı

Geliştirilen sistem, Android işletim sistemi üzerinde çalışan çok katmanlı bir mobil uygulama mimarisine sahiptir. Sistem mimarisi; kullanıcı arayüzü katmanı, görüntü edinim ve ön işleme katmanı, makine öğrenmesi çıkarım (inference) katmanı ve sonuç görselleştirme katmanlarından oluşmaktadır.

Genel iş akışı aşağıdaki adımlardan oluşmaktadır:

Android Kamera API → Görüntü Ön İşleme → TensorFlow Lite Segmentasyon Modeli → Pseudo-Spektral (NIR) Analiz → Sonuç Görselleştirme



Şekil 4.1: Sistem mimarisi ve genel iş akışı.

Kullanıcı tarafından kamera aracılığıyla elde edilen görüntüler, gerçek zamanlı olarak uygulama içerisinde işlenmekte ve segmentasyon modeli tarafından analiz edilmektedir. Tüm bu işlemler mobil cihaz üzerinde gerçekleştirilmektedir.

4.2 Mobil Görüntü Edinimi ve Ön İşleme Süreci

Mobil uygulamada görüntü edinimi, Android CameraX API kullanılarak gerçekleştirilmiştir. CameraX, farklı donanım yapılarına sahip cihazlarda tutarlı performans sunması nedeniyle tercih edilmiştir. Kamera akışından alınan görüntüler, belirli aralıklarla işlenerek modele beslenmektedir.

Elde edilen görüntüler üzerinde yeniden boyutlandırma, normalizasyon ve renk uzayı düzenlemeleri gibi ön işleme adımları uygulanmaktadır. Bu işlemler, modelin eğitim aşamasında kullanılan veri formatı ile uyumluluğu sağlamak amacıyla gerçekleştirilmiştir. Ön işleme süreci, gerçek zamanlı çalışmayı engellemeyecek şekilde optimize edilmiştir.

4.3 TensorFlow Lite Model Entegrasyonu

Eğitilen hafifletilmiş U-Net tabanlı segmentasyon modeli, TensorFlow Lite formatına dönüştürülerek mobil uygulamaya entegre edilmiştir. Model entegrasyonu sırasında TensorFlow Lite Interpreter kullanılmış ve INT8 quantization uygulanmış model tercih edilmiştir.

Bu sayede modelin bellek kullanımı azaltılmış ve çıkarım süresi kısaltılmıştır. Mobil cihaz üzerinde yapılan testlerde model, gerçek zamanlı çalışabilecek performans seviyesine ulaşmıştır. Model çıktısı, her bir piksel için sınıf olasılıklarını içeren bir segmentasyon maskesi şeklinde elde edilmektedir.

4.4 Gerçek Zamanlı Segmentasyon ve Pseudo-Spektral Analiz

Segmentasyon modeli tarafından üretilen maske, uygulama içerisinde anlık olarak işlenmekte ve orijinal kamera görüntüsü üzerine bindirilerek kullanıcıya sunulmaktadır. Bu görselleştirme, yarı saydam renk katmanları kullanılarak gerçekleştirilmiştir.

Ayrıca RGB görüntülerden tahmin edilen pseudo-spektral (NIR benzeri) bant, segmentasyon sürecini desteklemek amacıyla kullanılmaktadır. Bu bant sayesinde, düşük kontrastlı veya erken evre hastalık belirtilerinin daha belirgin hale getirilmesi sağlanmıştır. Pseudo-spektral analiz, mobil cihazın hesaplama kapasitesini zorlamayacak şekilde optimize edilmiştir.

4.5 Kullanıcı Arayüzü Tasarımı

Mobil uygulamanın kullanıcı arayüzü, Android platformuna uygun olarak sade ve kullanıcı dostu bir yaklaşımla tasarlanmıştır. Arayüzde canlı kamera görüntüsü, segmentasyon maskesi ve hesaplanan hastalık oranı eş zamanlı olarak gösterilmektedir.

Kullanıcı, uygulama üzerinden analiz edilen görüntüyü kaydedebilmekte ve farklı zamanlarda elde edilen sonuçları karşılaştırabilmektedir. Arayüz tasarımında, tarım alanında çalışan kullanıcıların teknik bilgi gereksinimi minimumda tutulmuştur.

Uygulama, SQLite tabanlı yerel bir veritabanı ile entegre edilmiştir; kullanıcılar yaptıkları analizleri tarih, saat ve isteğe bağlı konum bilgisiyle kaydedebilmektedir. Bu veriler yalnızca cihaz üzerinde tutulmakta, herhangi bir sunucuya veya bulut servisine iletilmemektedir; bu sayede sistemin tamamen çevrimdışı (offline) ve gizlilik odaklı çalışması sağlanmaktadır.

4.6 Mobil Performans ve Kaynak Kullanımı Değerlendirmesi

Geliştirilen sistemin mobil performansı, gerçek bir Android cihaza erişim kısıtı nedeniyle Android Emülatörü üzerinde (PC: Intel Core i7-11800H, 16 GB RAM, Windows 11) test edilmiştir. Yapılan ölçümlerde uygulamanın saniyede ortalama 15-18 kare işleyebildiği gözlemlenmiştir. Bu sonuçların gerçek mobil donanım kısıtları altında da geçerliliğinin doğrulanması gerekmektedir.

Bu sonuçlar, geliştirilen uygulamanın gerçek saha koşullarında uzun süreli kullanım için uygun olduğunu göstermektedir.

5. SONUÇ VE DEĞERLEDİRME

Bu bölümde, geliştirilen mobil yaprak hastalığı tespit sisteminin mevcut durumu özetlenmekte ve çalışmanın kapsamı doğrultusunda elde edilen bulgular değerlendirilmektedir. Ayrıca, ilerleyen aşamalarda gerçekleştirilebilecek olası geliştirme ve iyileştirme çalışmaları ele alınmaktadır.

5.1 Mevcut Durum Analizi

Bu bitirme tezi kapsamında, mobil cihazlar üzerinde gerçek zamanlı çalışabilen yaprak hastalığı segmentasyon ve analiz sistemi başarıyla geliştirilmiştir. Android işletim sistemi üzerinde çalışan uygulama, kamera girdisini doğrudan alarak TensorFlow Lite tabanlı derin öğrenme modeli ile analiz edebilmektedir. Geliştirilen sistemde, hafifletilmiş U-Net mimarisi kullanılarak yaprak üzerindeki hastalıklı bölgeler piksel düzeyinde tespit edilmiştir. Uygulanan INT8 quantization ve TensorFlow Lite optimizasyonları sayesinde model, mobil cihazlarda kabul edilebilir doğruluk değerleri ile gerçek zamanlı çalışabilir hale getirilmiştir. Yapılan deneysel değerlendirmelerde sistemin Android Emülatöründe saniyede ortalama 15-18 kare işleyebildiği gözlemlenmiştir; bu sonuçların gerçek mobil donanımda da geçerli olup olmadığı henüz doğrulanmamıştır. Ayrıca, RGB görüntülerden tahmin edilen pseudo-spektral (NIR benzeri) bant kullanımı sayesinde, özellikle erken evre ve düşük kontrastlı hastalık belirtilerinin tespitinde performans artışı sağlanmıştır. Bu durum, geliştirilen yaklaşımın pratik tarım uygulamaları açısından potansiyelini ortaya koymaktadır.

Uygulamamızla beraber test ettiğimiz bazı hastalık görüntü ve oranları aşağıda verilmiştir:




Figure 5.1.1




Figure 5.1.2

5.2 Gelecek Çalışmalar ve Planlanan Geliştirmeler

Bu çalışmanın devamında gerçekleştirilebilecek geliştirme faaliyetleri aşağıda özetlenmiştir:

- **Model Performansının Artırılması:** Daha geniş ve farklı bitki türlerini kapsayan veri setleri ile modelin yeniden eğitilmesi ve genelleme yeteneğinin artırılması planlanmaktadır.
- **Çoklu Hastalık ve Bitki Türü Desteği:** Mevcut sistemin farklı bitki türleri ve birden fazla hastalık sınıfını aynı anda tespit edebilecek şekilde genişletilmesi hedeflenmektedir.
- **Mobil Performans Optimizasyonu:** Farklı donanım özelliklerine sahip mobil cihazlar üzerinde detaylı performans testleri yapılarak bellek kullanımı ve enerji tüketiminin daha da optimize edilmesi amaçlanmaktadır.
- **Kullanıcı Arayüzü İyileştirmeleri:** Tarım alanında çalışan kullanıcıların geri bildirimleri doğrultusunda arayüzün kullanılabilirliğinin artırılması ve görsel çıktının daha anlaşılır hale getirilmesi planlanmaktadır.
- **Saha Testleri ve Gerçek Ortam Uygulamaları:** Geliştirilen sistemin farklı ışık koşulları ve gerçek tarım alanlarında test edilerek saha koşullarındaki başarımının değerlendirilmesi hedeflenmektedir.

Gerçek Mobil Cihaz Testleri:

Bu çalışmada performans ölçümleri Android Emülatörü (PC tabanlı) üzerinde gerçekleştirilmiştir; gerçek mobil donanımın (sınırlı RAM, ARM mimarisi, termal kısıtlar) FPS ve bellek kullanımı üzerindeki etkisinin ölçülmesi planlanmaktadır.

- Bu planlanan çalışmalar ile birlikte, geliştirilen mobil yaprak hastalığı tespit sisteminin hem akademik hem de pratik uygulamalar açısından daha güçlü bir karar destek aracı haline getirilmesi amaçlanmaktadır.

KAYNAKLAR

- [1] Barbedo, J. G. A. (2019). Plant disease identification from individual lesions and spots using deep learning. *Biosystems Engineering*, 180, 96-107. <https://doi.org/10.1016/j.biosystemseng.2019.02.002>
- [2] Zhang, J., Su, R., Fu, Q., Ren, W., Heide, F., & Nie, Y. (2022). A survey on computational spectral reconstruction methods from RGB to hyperspectral imaging. *Scientific Reports*, 12(1), 11905. <https://doi.org/10.1038/s41598-022-16223-1>
- [3] Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419. <https://doi.org/10.3389/fpls.2016.01419>
- [4] Nnamdi, U. V., & Abolghasemi, V. (2025). Optimised MobileNet for very lightweight and accurate plant leaf disease detection. *Scientific Reports*, 15, 43690. <https://doi.org/10.1038/s41598-025-27393-z>
- [5] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015)*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28
- [6] Hughes, D. P., & Salathé, M. (2015). An open access repository of images on plant health to enable the development of mobile disease diagnostics through machine learning and crowdsourcing. *arXiv:1511.08060*.

Kişisel Bilgiler

- **Adı Soyadı:** Hazan Ezgi Erçin
- **Doğum Yeri ve Tarihi:** Zonguldak / Ereğli, 05.07.2001

Eğitim Durumu

- **Lisans:** Bandırma Onyedi Eylül Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2023-2026.
- **Lisans:** Antalya Bilim Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2022-2023.
- **Lisans:** İstinye Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2020-2022.
- **Lise:** Özel Kampüs Temel Lisesi, 2017-2019.

İlgi Alanları

- **Görüntü İşleme**
- **Web Uygulama Geliştirme** (Full-stack Development)
- **Makine Öğrenmesi ve Yapay Zeka**
- **Medikal/Sağlık Yazılım Çözümleri**

Diller

- **Türkçe:** Ana Dil
- **İngilizce:** İyi Seviye (B2)
- **Almanca:** Başlangıç Seviyesi (A2)

Kişisel Bilgiler

- **Adı Soyadı:** Fatih Taşkın
- **Doğum Yeri ve Tarihi:** İstanbul / Kartal, 04.08.2001

Eğitim Durumu

- **Lisans:** Bandırma Onyedi Eylül Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü (İngilizce) 2021-2026.
- **Lise:** Atilla Uras Anadolu Lisesi- Maltepe/İstanbul, 2015-2019.
- **Ortaokul:** Ercan Görür İlköğretim Okulu- Pendik/İstanbul, 2008-2015

İlgi Alanları

- **Görüntü İşleme (Computer Vision)**
- **Web Uygulama Geliştirme (Full-stack Development)**
- **Makine Öğrenmesi ve Yapay Zeka**
- **Veri, Performans ve Sistem Analizi**

Diller

- **Türkçe:** Ana Dil
- **İngilizce:** İyi Seviye (B2)